




Laboratorio 1: Minería de texto y procesamiento de lenguaje natural

Ingeniería Informática

Juan Camilo Grisales Arias

Asignatura: Minería de texto y procesamiento de lenguaje natural

Estudiante: Juan Camilo Grisales Arias

Fecha: Agosto de 2026

Contenido

1. Resumen y alcance	1
1.1. Trazabilidad frente a la rúbrica	1
2. Corpus y metodología	2
2.1. Selección de las obras	2
2.2. Entorno y reproducibilidad	2
2.3. Preprocesamiento	2
3. Términos más frecuentes y nubes de palabras	3
3.1. The Eyes Have It	3
3.2. Keep Out	4
3.3. Navy Day	5
3.4. 2 B R O 2 B	6
4. Análisis TF-IDF	8
4.1. Definición	8
4.2. Quince términos más característicos	8
5. Comparación: frecuencia frente a términos característicos	11
5.1. Interpretación por obra	11
6. Asociaciones entre palabras	12
6.1. Método	12
6.2. Keep Out: asociaciones de “mars”	13
6.3. Navy Day: asociaciones de “army”	14
7. Discusión	15
8. Conclusiones	15
9. Apéndice: reproducibilidad y archivos entregados	15
10. Referencias	16

Resumen y alcance

El laboratorio aplica técnicas de minería de texto y procesamiento de lenguaje natural a un corpus homogéneo de cuatro obras de ciencia ficción disponibles como eBooks de Project Gutenberg. Se analizan **The Eyes Have It** de Philip K. Dick, **Keep Out** de Fredric Brown, **Navy Day** de Harry Harrison y **2 B R 0 2 B** de Kurt Vonnegut. La selección mantiene una misma categoría temática y, al mismo tiempo, utiliza cuatro autores distintos para favorecer la comparación de vocabulario específico entre documentos.

El desarrollo cubre de forma explícita todos los puntos solicitados: construcción del corpus, depuración y tokenización, identificación de los quince términos más frecuentes, cuatro nubes de palabras, cálculo de TF-IDF, identificación y representación de los quince términos más característicos, comparación entre frecuencia y TF-IDF y asociaciones por coocurrencia para términos distintivos de dos obras.

Resultado global. El análisis confirma que la frecuencia absoluta captura el vocabulario dominante dentro de cada obra, mientras que TF-IDF penaliza términos compartidos y eleva vocabulario distintivo. Esta diferencia es especialmente visible en **Keep Out**: **years** es el término más frecuente, pero **mars** pasa al primer lugar por TF-IDF.

Trazabilidad frente a la rúbrica

Criterio	Evidencia en el informe	Entregable
Corpus de cuatro libros	Sección “Corpus y metodología”	Código + Tabla 1
15 términos frecuentes y nube por libro	Sección “Frecuencias y nubes”	8 gráficas
TF-IDF de los cuatro libros	Sección “Análisis TF-IDF”	Tabla + CSV
15 términos característicos por libro	Sección “Análisis TF-IDF”	4 gráficas
Comparación frecuencia vs. característicos	Sección “Comparación”	Tabla + gráfica
Asociaciones de al menos dos términos	Sección “Asociaciones”	2 tablas + 2 gráficas
Código fuente	Apéndice metodológico	laboratorio1_mineria_texto.py

Corpus y metodología

Selección de las obras

Las cuatro obras pertenecen a la categoría **Science fiction** de Project Gutenberg y aparecen también identificadas como relatos cortos. Se eligieron textos de autores diferentes para que el índice TF-IDF no se limite a capturar únicamente hábitos léxicos de un mismo escritor.

Obra	Autor	ID PG	Tokens lim-pios	Vocabulario
The Eyes Have It	Philip K. Dick	31516	398	316
Keep Out	Fredric Brown	29142	473	317
Navy Day	Harry Harrison	30019	870	682
2 B R O 2 B	Kurt Vonnegut	21279	964	606

Nota. Los tokens y el vocabulario se contabilizan después de normalizar a minúsculas, conservar unidades alfabéticas de más de dos caracteres y retirar stopwords. Elaboración propia.

Entorno y reproducibilidad

El análisis se implementó y ejecutó íntegramente en **Python 3**, opción autorizada por el docente. Se utilizaron *pandas* para estructurar resultados, *scikit-learn* únicamente para disponer de una lista estándar de stopwords en inglés, *matplotlib* para las gráficas y *wordcloud* para las nubes. El archivo fuente incluido en la entrega descarga automáticamente las versiones de texto plano desde Project Gutenberg, por lo que el procedimiento puede reproducirse en un equipo local o en Google Colab.

Decisión metodológica. No se aplicó stemming ni lematización. La decisión es deliberada: en relatos cortos, nombres propios y variantes léxicas como **Martians**, **Wehling**, **Hitz** o **Wingrove** son señales semánticas útiles para caracterizar cada documento. Se evita así perder información discriminante por una normalización excesiva.

Preprocesamiento

El flujo aplicado a cada documento fue: obtención del texto, eliminación del encabezado y licencia de Project Gutenberg, aislamiento del relato mediante anclas de su primer y último párrafo, paso a minúsculas, tokenización mediante expresión regular, descarte de tokens de dos caracteres o menos y eliminación de stopwords estándar y editoriales. También se eliminaron verbos narrativos muy frecuentes como **said**, contracciones y términos editoriales como **ebook** y **gutenberg**.

Fragmento relevante: tokenización y limpieza

```
def tokenize(text):
    tokens = []
```

```
for raw in TOKEN_RE.findall(text.lower()):
    word = raw.strip("'")
    if len(word) <= 2 or word in STOPWORDS:
        continue
    tokens.append(word)
return tokens
```

Términos más frecuentes y nubes de palabras

La frecuencia absoluta permite una primera lectura del contenido de cada obra. La Tabla 2 muestra los quince términos con mayor número de apariciones después del preprocesamiento.

Pos.	The Eyes Have It	Keep Out	Navy Day	2 B R O 2 B
1	eyes (9)	years (12)	army (13)	wehling (22)
2	julia (6)	mars (9)	navy (12)	hitz (21)
3	arm (4)	air (8)	congress (9)	painter (14)
4	heart (4)	conditions (7)	general (9)	people (13)
5	passage (4)	dome (7)	water (7)	duncan (12)
6	beings (3)	martians (7)	admiral (6)	orderly (11)
7	earth (3)	earth (6)	surface (6)	happy (10)
8	incredible (3)	live (6)	forward (5)	old (10)
9	knowledge (3)	children (5)	gentlemen (5)	good (7)
10	obviously (3)	gradually (5)	wingrove (5)	leora (7)
11	quite (3)	tomorrow (5)	line (4)	triplets (7)
12	reference (3)	kill (4)	morning (4)	life (6)
13	species (3)	long (4)	naval (4)	live (6)
14	wife (3)	planet (4)	sea (4)	mural (6)
15	absolutely (2)	space (4)	world (4)	number (6)

Nota. Cada celda muestra término y frecuencia absoluta entre paréntesis.

The Eyes Have It

La palabra **eyes** (9) encabeza la frecuencia, seguida por **julia** (6). El patrón concuerda con el mecanismo humorístico del relato: el narrador interpreta literalmente expresiones idiomáticas relacionadas con partes del cuerpo.




Figura 1: Quince términos más frecuentes en *The Eyes Have It*.






Figura 2: Nube de palabras de *The Eyes Have It*.

Keep Out


En **Keep Out** predominan **years** (12), **mars** (9), **air** (8) y el grupo **conditions, dome** y **martians** (7 cada uno). El vocabulario refleja de forma directa el proceso de adaptación biológica de los niños destinados a colonizar Marte.



Navy Day presenta un campo léxico institucional muy marcado: **army** (13), **navy** (12), **congress** y **general** (9), además de **admiral**, **naval** y términos relacionados con agua, superficie y navegación. La frecuencia anticipa el conflicto satírico entre las dos fuerzas militares.



En **2 B R O 2 B** dominan los nombres **Wehling** (22), **Hitz** (21), **Duncan** (12) y **Leora** (7), acompañados por **painter** (14), **orderly** (11), **happy** (10) y **triplets** (7). Esto identifica con claridad a los actores y elementos centrales de la distopía demográfica.



Análisis TF-IDF

Definición

Para evitar confundir “muy frecuente” con “característico”, se calculó TF-IDF sobre los cuatro documentos. La frecuencia de término se normalizó por el número total de tokens limpios del documento y la frecuencia inversa de documento se calculó sin suavizado:

$$TF(t, d) = \frac{n_{t,d}}{\sum_k n_{k,d}}$$

$$IDF(t) = \ln\left(\frac{N}{df(t)}\right)$$

$$TF-IDF(t, d) = TF(t, d) \times IDF(t)$$

Aquí, $N = 4$ es el número de obras y $df(t)$ indica en cuántas obras aparece el término. Por tanto, una palabra exclusiva de un libro recibe mayor IDF que otra compartida por dos, tres o cuatro textos.

Fragmento relevante: cálculo explícito de TF-IDF

```
out["tf"] = out.apply(
    lambda r: r["frecuencia"] / totals[r["libro"]], axis=1
)
out["df"] = out["termino"].map(doc_freq)
out["idf"] = out["df"].map(lambda df: math.log(n_docs / df))
out["tf_idf"] = out["tf"] * out["idf"]
```

Quince términos más característicos

Pos.	The Eyes Have It	Keep Out	Navy Day	2 B R 0 2 B
1	julia (0,0209)	mars (0,0264)	army (0,0207)	wehling (0,0316)
2	eyes (0,0157)	conditions (0,0205)	navy (0,0191)	hitz (0,0302)
3	heart (0,0139)	martians (0,0205)	general (0,0143)	painter (0,0201)
4	arm (0,0139)	dome (0,0205)	congress (0,0143)	duncan (0,0173)
5	species (0,0104)	years (0,0176)	admiral (0,0096)	orderly (0,0158)
6	incredible (0,0104)	gradually (0,0147)	gentlemen (0,0080)	triplets (0,0101)
7	knowledge (0,0104)	teachers (0,0117)	forward (0,0080)	leora (0,0101)
8	reference (0,0104)	kill (0,0117)	wingrove (0,0080)	mural (0,0086)
9	obviously (0,0104)	live (0,0088)	naval (0,0064)	population (0,0086)
10	passage (0,0070)	food (0,0088)	water (0,0056)	purple (0,0086)
11	leaped (0,0070)	glassite (0,0088)	attack (0,0048)	old (0,0072)
12	garage (0,0070)	changing (0,0088)	silence (0,0048)	happy (0,0072)
13	followed (0,0070)	cold (0,0088)	cars (0,0048)	thanks (0,0072)
14	bibney (0,0070)	progeny (0,0088)	trucks (0,0048)	garden (0,0072)
15	race (0,0070)	earthmen (0,0088)	carriers (0,0048)	termination (0,0058)

Nota. Cada celda presenta el término y su TF-IDF redondeado a cuatro decimales.




Figura 9: Quince términos con mayor TF-IDF en *The Eyes Have It*.




Figura 10: Quince términos con mayor TF-IDF en *Keep Out*.




Figura 11: Quince términos con mayor TF-IDF en *Navy Day*.




Figura 12: Quince términos con mayor TF-IDF en *2 B R 0 2 B*.

La diferenciación es semánticamente coherente. **The Eyes Have It** queda caracterizado por **Julia, eyes, heart, arm** y **species**; **Keep Out** por **mars, conditions**,

martians y dome; Navy Day por army, navy, general, congress y admiral; y 2 B R 0 2 B por Wehling, Hitz, painter, Duncan y orderly.

Comparación: frecuencia frente a términos característicos

La comparación entre ambos rankings muestra que una palabra puede ser muy frecuente sin ser la más distintiva. El porcentaje de solapamiento entre las dos listas de quince términos se sitúa entre 53,3 % y 66,7 %.

Obra	Coincid.	Solapamiento	Términos presentes en ambos top 15
The Eyes Have It	10/15	66,7 %	arm, eyes, heart, incredible, julia, knowledge, obviously, passage, reference, species
Keep Out	8/15	53,3 %	conditions, dome, gradually, kill, live, mars, martians, years
Navy Day	10/15	66,7 %	admiral, army, congress, forward, general, gentlemen, naval, navy, water, wingrove
2 B R 0 2 B	10/15	66,7 %	duncan, happy, hitz, leora, mural, old, orderly, painter, triplets, wehling




Figura 13: Número de términos coincidentes entre el top 15 por frecuencia y por TF-IDF.

Interpretación por obra

The Eyes Have It. **Eyes** es la palabra más frecuente, pero **Julia** obtiene el TF-IDF más alto. La razón es que **eyes** también aparece en otra obra del corpus y, por ello, su IDF se reduce. TF-

IDF destaca además **heart**, **arm** y **species**, que condensan la lectura literal de expresiones anatómicas que sostiene el relato.

Keep Out. Aquí se observa la diferencia más clara: **years** aparece doce veces y lidera la frecuencia absoluta, pero **mars** pasa al primer puesto en TF-IDF. **Conditions**, **martians**, **dome**, **gradually** y **teachers** también ganan importancia relativa. El ranking característico describe mejor el experimento de adaptación al ambiente marciano que una lista puramente frecuente.

Navy Day. Los dos enfoques son muy consistentes. **Army**, **navy**, **general**, **congress** y **admiral** dominan frecuencia y TF-IDF porque son repetidos y prácticamente exclusivos de la obra. El 66,7 % de coincidencia confirma un campo léxico altamente concentrado.

2 B R O 2 B. Los nombres **Wehling**, **Hitz** y **Duncan** continúan dominando, pero TF-IDF incorpora con mayor fuerza **triplets**, **population**, **mural**, **purple** y **termination**. En cambio, **people**, aunque frecuente, no entra entre los términos más característicos porque es menos exclusivo. TF-IDF ayuda así a separar vocabulario narrativo general de los mecanismos particulares de la sociedad distópica.

Asociaciones entre palabras

Método

Para estudiar asociaciones internas no basta con tratar cada libro como un único documento. Por ello, cada obra se dividió en segmentos contiguos de 80 tokens limpios; cada segmento funciona como pseudodocumento. Para una palabra se construyó un vector binario que indica presencia o ausencia en cada segmento. La asociación entre dos términos se estimó mediante la correlación de Pearson de esos vectores. Solo se consideraron palabras con frecuencia global mínima de tres y presencia en al menos dos segmentos.

La correlación obtenida mide **coocurrencia contextual**, no causalidad. Un valor alto indica que los términos tienden a aparecer en los mismos segmentos del relato, por lo que resulta útil como aproximación cuantitativa a la asociación temática.

Fragmento relevante: asociación por coocurrencia

```
target_vec = np.array([
    1.0 if target in segment else 0.0
    for segment in segment_sets
])
vec = np.array([
    1.0 if word in segment else 0.0
    for segment in segment_sets
])
corr = float(np.corrcoef(target_vec, vec)[0, 1])
```

Keep Out: asociaciones de “mars”

Mars fue el término con mayor TF-IDF de **Keep Out** (0,0264), por lo que cumple directamente el requisito de utilizar un término característico.

Pos.	Término asociado	Correlación	Frecuencia
1	children	0,632	5
2	conditions	0,447	7
3	martians	0,447	7
4	gradually	0,447	5
5	long	0,447	4
6	space	0,447	4
7	inside	0,447	3
8	temperature	0,447	3
9	cold	0,447	3
10	glassite	0,316	3




Figura 14: Principales asociaciones de *mars* en *Keep Out*.

La asociación más fuerte es **children** ($r = 0,632$). También aparecen **conditions**, **martians**, **gradually**, **space**, **temperature** y **cold**. La estructura de asociaciones reconstruye cuantitativamente el eje central del relato: niños sometidos a cambios graduales de condiciones para convertirse en habitantes adaptados a Marte.

Navy Day: asociaciones de “army”

Army es el término de mayor TF-IDF en **Navy Day** (0,0207). Sus asociaciones más altas corresponden a vocabulario directamente relacionado con la rivalidad militar y la expansión de capacidades sobre tierra y mar.

Pos.	Término asociado	Correlación	Frecuencia
1	naval	0,463	4
2	navy	0,386	12
3	world	0,375	4
4	sea	0,375	4
5	turned	0,375	3
6	land	0,375	3
7	states	0,289	3
8	battleships	0,289	3
9	gentlemen	0,039	5
10	water	0,039	7




Figura 15: Principales asociaciones de *army* en *Navy Day*.

Naval ($r = 0,463$) y **navy** ($r = 0,386$) ocupan las primeras posiciones, seguidas por términos vinculados con el alcance territorial como **world**, **sea** y **land**. La coocurrencia es consistente con la premisa satírica: el Ejército demuestra una tecnología para operar sobre el agua y la Marina responde con una tecnología para desplazarse sobre tierra.

Discusión

Los resultados muestran tres ventajas de combinar frecuencia, TF-IDF y asociaciones. Primero, la frecuencia ofrece una descripción intuitiva pero puede privilegiar términos compartidos o generales. Segundo, TF-IDF identifica vocabulario que simultáneamente es relevante dentro de una obra y raro en el resto del corpus. Tercero, las asociaciones recuperan relaciones internas que una lista ordenada no puede mostrar por sí sola.

El tamaño desigual de las obras no invalida la comparación porque el componente TF utiliza frecuencia relativa y no conteos brutos. Sin embargo, el corpus es pequeño ($N = 4$), por lo que el IDF solo puede adoptar unos pocos niveles. En un corpus de cientos de documentos se obtendría una gradación más fina de especificidad. Esta limitación es inherente al enunciado, que solicita únicamente cuatro libros, y no impide cumplir el objetivo exploratorio del laboratorio.

También debe considerarse que las nubes de palabras son representaciones visuales y no sustituyen una medida cuantitativa. En este informe se utilizan como apoyo exploratorio, mientras que las conclusiones principales se fundamentan en tablas de frecuencia, TF-IDF y correlaciones de coocurrencia.

Conclusiones

1. Se construyó y procesó correctamente un corpus de cuatro eBooks de ciencia ficción de Project Gutenberg, con un total de **2.705 tokens limpios** y vocabularios individuales entre 316 y 682 términos.
2. Los términos frecuentes describen adecuadamente el contenido, pero TF-IDF produce una caracterización más discriminante. El ejemplo más evidente es **Keep Out: years** lidera por frecuencia, mientras **mars** lidera por TF-IDF.
3. Los términos de mayor TF-IDF son interpretables narrativamente: **Julia/eyes/heart/arm** en *The Eyes Have It*; **mars/conditions/martians/dome** en *Keep Out*; **army/navy/general/congress** en *Navy Day*; y **Wehling/Hitz/painter/Duncan** en *2 B R O 2 B*.
4. Las asociaciones por segmentos aportan evidencia adicional: **mars** se relaciona con **children** y el proceso de adaptación ambiental, mientras **army** se relaciona con **naval, navy, sea** y **land**. Los resultados son coherentes con la temática de ambas obras.

Apéndice: reproducibilidad y archivos entregados

La ejecución completa está contenida en `laboratorio1_mineria_texto.py`. El script puede ejecutarse con:

```
python laboratorio1_mineria_texto.py
```

Dependencias principales:

```
uv add pandas numpy matplotlib scikit-learn wordcloud requests
```

La carpeta `assets/` contiene el logo institucional y las quince gráficas utilizadas; `results/` conserva los CSV completos y el resumen JSON que permiten auditar los valores presentados en el informe. También se incluye un notebook `.ipynb` preparado como punto de entrada para Google Colab.

Referencias

- Brown, F. (2009). *Keep Out* (eBook No. 29142). Project Gutenberg. <https://www.gutenberg.org/ebooks/29142>
- Dick, P. K. (2010). *The Eyes Have It* (eBook No. 31516). Project Gutenberg. <https://www.gutenberg.org/ebooks/31516>
- Harrison, H. (2009). *Navy Day* (eBook No. 30019). Project Gutenberg. <https://www.gutenberg.org/ebooks/30019>
- Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95. <https://doi.org/10.1109/MCSE.2007.55>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513–523. [https://doi.org/10.1016/0306-4573\(88\)90021-0](https://doi.org/10.1016/0306-4573(88)90021-0)
- Vonnegut, K. (2007). *2 B R O 2 B* (eBook No. 21279). Project Gutenberg. <https://www.gutenberg.org/ebooks/21279>